

ĐẠI HỌC KINH TẾ TP. HỒ CHÍ MINH
TRƯỜNG CÔNG NGHỆ VÀ THIẾT KẾ
KHOA CÔNG NGHỆ THÔNG TIN KINH DOANH

□ □ □ □ □



BÁO CÁO ĐỒ ÁN CUỐI KỲ
MÔN: NHẬP MÔN HỌC SÂU

ĐỀ TÀI: PHÂN ĐOẠN MẠCH MÁU VĨNG MẠC BẰNG MÔ HÌNH
DEEPLABV3+-RESNET50 VÀ SEGFORMER-B0 VỚI PHƯƠNG PHÁP
TRANSFER LEARNING

Giảng viên hướng dẫn TS.Đặng Ngọc Hoàng Thành

Mã lớp học phần 26D1INF50916301

Khóa 49

Nhóm sinh viên thực hiện

Nguyễn Quốc Khánh 31231021198

Ngô Chánh Phong 31231021197

Dương Quang Đông 31231020389

Nguyễn Đình Lương 31231027411

Thành phố Hồ Chí Minh, ngày 08 tháng 06 năm 2026

LỜI MỞ ĐẦU

Trước hết, nhóm chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến **TS. Đặng Ngọc Hoàng Thành**, giảng viên hướng dẫn môn **Deep Learning**, người đã tận tình chỉ bảo và đồng hành cùng chúng em trong suốt quá trình thực hiện dự án. Thầy không chỉ truyền đạt cho chúng em những kiến thức chuyên môn quý báu mà còn chia sẻ nhiều kinh nghiệm thực tiễn vô cùng hữu ích. Nhờ có sự hướng dẫn tận tâm của Thầy, chúng em đã có cơ hội vận dụng lý thuyết vào thực hành một cách hiệu quả, qua đó hiểu sâu hơn về lĩnh vực thiết kế mạng nơ-ron, thuật toán tối ưu và cách triển khai các mô hình học sâu.

Dự án cuối kỳ với chủ đề “**Ứng dụng DeepLabV3+-ResNet50 và SegFormer-B0 cho phân đoạn mạch máu võng mạc với**” được thực hiện bởi Nhóm, là một thử thách đồng thời cũng là cơ hội quý giá để chúng em áp dụng toàn diện những kiến thức đã học. Dự án đòi hỏi không chỉ năng lực chuyên môn kỹ thuật trong việc xây dựng kiến trúc mô hình mà còn yêu cầu sự phối hợp chặt chẽ giữa các thành viên, tư duy hệ thống và khả năng giải quyết vấn đề linh hoạt để xây dựng một pipelines huấn luyện hoàn chỉnh. Trong suốt quá trình thực hiện, nhóm đã không ngừng nghiên cứu và tìm kiếm các giải pháp tối ưu cho mô hình, từ việc thu thập, tiền xử lý và Data Augmentation, lựa chọn kiến trúc mạng nơ-ron phù hợp, cho đến việc tinh chỉnh các siêu tham số và tối ưu hóa loss function nhằm đạt được hiệu suất và độ chính xác cao nhất.

Việc phân tích, thiết kế và huấn luyện một mô hình Học sâu từ dữ liệu thô đã mang đến cho chúng em nhiều bài học quý báu, giúp phát triển tư duy phân tích dữ liệu cũng như kỹ năng xử lý vấn đề thực tiễn trong lĩnh vực Trí tuệ nhân tạo và ứng dụng các thuật toán tiên tiến vào giải quyết bài toán thực tế.

Một lần nữa, chúng em xin chân thành gửi lời tri ân đến **TS. Đặng Ngọc Hoàng Thành** vì sự tận tâm và hướng dẫn quý báu trong suốt quá trình thực hiện dự án.

Trân trọng cảm ơn!

MỤC LỤC

LỜI MỞ ĐẦU.....	1
MỤC LỤC.....	2
CHƯƠNG 1: GIỚI THIỆU TỔNG QUAN.....	4
1.1. Tổng quan bài toán.....	4
1.2 Mục tiêu và phạm vi đề án.....	4
1.2.1 Mục tiêu đề án.....	4
1.2.2 Phạm vi đề án.....	5
CHƯƠNG 2: DỮ LIỆU VÀ TIỀN XỬ LÝ.....	6
2.1. Mô tả dữ liệu.....	6
2.1.1. CHASEDB1.....	6
2.2.2. DRIVE.....	6
2.2. Tiền xử lý và DataLoader.....	7
2.2.1. Đọc ảnh bằng Dataset class.....	7
2.2.2. Resize các ảnh và mask về cùng kích thước.....	8
2.2.3. Normalize ảnh.....	8
2.2.4. Chuyển mask về binary 0/1.....	9
2.2.5. Data augmentation.....	9
2.2.6. DataLoader.....	9
CHƯƠNG 3: PHƯƠNG PHÁP ĐỀ XUẤT.....	11
3.1 Mô Hình CNN-Based: DeepLabV3+-ResNet50.....	11
3.1.1. Cài đặt mô hình cho bài toán phân vùng nhị phân.....	11
3.1.2. Xử lý luồng dữ liệu và nội suy không gian Input/Output Shape.....	12
3.2. Kiến trúc mô hình SegFormer-B0.....	13
3.2.1. Cài đặt mô hình cho bài toán phân vùng nhị phân.....	13
3.2.2. Xử lý luồng dữ liệu và nội suy không gian Input/Output Shape.....	14
3.3 Loss function, metrics và transfer learning.....	14
3.3.1. Hàm mất mát và vấn đề mất cân bằng lớp.....	14
3.3.2. Thang đo đánh giá.....	15
3.3.3. Transfer Learning.....	16
3.3.4. Chiến lược tối ưu hóa và Huấn luyện.....	17
CHƯƠNG 4: THỰC NGHIỆM VÀ KẾT QUẢ.....	19
4.1 Thiết lập thực nghiệm.....	19
4.1.1. Môi trường thực nghiệm và Tính tái lập.....	19
4.1.2. Bảng tham số huấn luyện.....	19
4.1.3. Quy trình huấn luyện và lưu trữ.....	20

4.2. Kết quả từng mô hình.....	22
4.2.1. Kết quả mô hình DeepLabV3+-ResNet50.....	22
4.2.2. Kết quả mô hình SegFormer-B0.....	23
4.2.3. Nhận xét so sánh trực quan.....	24
4.3. So sánh và phân tích lỗi.....	24
4.3.1. So sánh trực quan.....	25
4.3.2. Phân tích lỗi.....	26
4.3.3. Ảnh hưởng của domain shift giữa CHASEDB1 và DRIVE.....	26
CHƯƠNG 5: ỨNG DỤNG DEMO.....	28
5.1 Mục tiêu và chức năng ứng dụng.....	28
5.1.1. Tải ảnh vồng mạc.....	29
5.1.2. Lựa chọn mô hình phân đoạn.....	29
5.1.3. Thực hiện phân đoạn tự động.....	30
5.1.4. Trực quan hóa kết quả.....	30
5.1.5. Phân tích đặc trưng mạch máu.....	31
5.1.6. Tải kết quả về máy.....	32
5.1.7. Technical Vessel Dashboard.....	32
5.2 Pipeline xử lý trong ứng dụng.....	33
CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	35
6.1 Tổng kết kết quả đạt được.....	35
6.2 Hạn chế và hướng phát triển.....	35
TÀI LIỆU THAM KHẢO.....	37
PHỤ LỤC.....	38

CHƯƠNG 1: GIỚI THIỆU TỔNG QUAN

1.1. Tổng quan bài toán

Trong những năm gần đây, bệnh lý võng mạc đang trở thành một trong những nguyên nhân hàng đầu gây suy giảm thị lực và mù lòa trên toàn thế giới. Các bệnh như bệnh võng mạc tiểu đường (Diabetic Retinopathy), tăng huyết áp võng mạc và tăng nhãn áp thường gây ra những biến đổi bất thường trên hệ thống mạch máu võng mạc. Vì vậy, việc phân tích cấu trúc mạch máu đóng vai trò quan trọng trong quá trình hỗ trợ chẩn đoán và theo dõi các bệnh lý về mắt.

Phân đoạn mạch máu võng mạc (Retinal Vessel Segmentation) là bài toán xác định chính xác vị trí các mạch máu trong ảnh đáy mắt (Fundus Image). Kết quả của quá trình phân đoạn thường được biểu diễn dưới dạng ảnh nhị phân, trong đó các điểm ảnh thuộc mạch máu được đánh dấu riêng biệt với vùng nền. Đây là bước tiền xử lý quan trọng cho nhiều hệ thống phân tích ảnh y khoa như phát hiện tổn thương võng mạc, phân tích hình thái mạch máu, đo mật độ mạch máu hoặc hỗ trợ chẩn đoán bệnh lý mắt.

Tuy nhiên, việc phân đoạn mạch máu võng mạc gặp nhiều thách thức do kích thước mạch máu rất nhỏ, độ tương phản thấp giữa mạch máu và nền ảnh, sự xuất hiện của nhiễu ảnh cũng như sự đa dạng về hình dạng và độ dày của các nhánh mạch máu. Các phương pháp xử lý ảnh truyền thống thường gặp khó khăn trong việc trích xuất đầy đủ hệ thống mạch máu, đặc biệt là các mạch máu nhỏ và mờ.

Sự phát triển mạnh mẽ của Deep Learning đã mở ra nhiều hướng tiếp cận hiệu quả cho bài toán phân đoạn ảnh. Các mô hình học sâu có khả năng tự động học đặc trưng từ dữ liệu và đạt được hiệu năng vượt trội so với các phương pháp truyền thống. Trong lĩnh vực phân đoạn ảnh y khoa, nhiều kiến trúc hiện đại như U-Net, DeepLabV3+ hay SegFormer đã được nghiên cứu và ứng dụng rộng rãi.

Trong đề án này, nhóm tập trung xây dựng hệ thống phân đoạn mạch máu võng mạc sử dụng Deep Learning trên các bộ dữ liệu chuẩn DRIVE và CHASEDB1. Hai mô hình SegFormer-B0 và DeepLabV3+-ResNet50 được triển khai và đánh giá nhằm so sánh hiệu năng phân đoạn. Bên cạnh đó, hệ thống còn được mở rộng thành một ứng dụng trực quan cho phép người dùng tải lên ảnh võng mạc, thực hiện phân đoạn tự động và phân tích một số đặc trưng cơ bản của hệ thống mạch máu.

1.2 Mục tiêu và phạm vi đề án

1.2.1 Mục tiêu đề án

Đề án hướng đến việc xây dựng một hệ thống phân đoạn mạch máu võng mạc hoàn chỉnh dựa trên các kỹ thuật Deep Learning hiện đại. Các mục tiêu cụ thể bao gồm:

- Nghiên cứu bài toán phân đoạn mạch máu võng mạc trong ảnh đáy mắt.
- Khảo sát và sử dụng các bộ dữ liệu chuẩn DRIVE và CHASEDB1 phục vụ quá trình huấn luyện và đánh giá mô hình.
- Tiền xử lý dữ liệu và xây dựng tập dữ liệu phù hợp cho quá trình học sâu.
- Triển khai mô hình SegFormer-B0 cho bài toán phân đoạn mạch máu võng mạc.
- Triển khai mô hình DeepLabV3+-ResNet50 nhằm mục đích so sánh hiệu năng.
- Đánh giá chất lượng mô hình thông qua các chỉ số Dice Score, Intersection over Union (IoU), Accuracy, Precision và Recall.
- Trực quan hóa kết quả phân đoạn thông qua ảnh gốc, ảnh dự đoán và ảnh chồng lớp (Overlay).
- Xây dựng ứng dụng Streamlit cho phép người dùng tải ảnh võng mạc và thực hiện phân đoạn tự động.
- Thực hiện phân tích cơ bản hệ thống mạch máu thông qua các chỉ số như Vessel Density, Branch Count, Junction Count và Risk Score.

1.2.2 Phạm vi đồ án

Trong phạm vi của đồ án, nhóm tập trung vào bài toán phân đoạn nhị phân mạch máu võng mạc từ ảnh đáy mắt. Dữ liệu sử dụng bao gồm hai bộ dữ liệu công khai là DRIVE và CHASEDB1. Các mô hình được triển khai chủ yếu bằng thư viện PyTorch.

Đồ án chỉ tập trung vào việc xác định vùng mạch máu trong ảnh võng mạc và đánh giá chất lượng phân đoạn. Hệ thống không thực hiện chẩn đoán bệnh lý, phân loại bệnh hay đưa ra kết luận y khoa. Các chỉ số phân tích mạch máu được xây dựng nhằm mục đích minh họa và hỗ trợ nghiên cứu học thuật.

Kết quả cuối cùng của đồ án bao gồm mô hình phân đoạn đã được huấn luyện, quy trình đánh giá hiệu năng, hệ thống trực quan hóa kết quả và ứng dụng Streamlit hỗ trợ thực hiện phân đoạn ảnh võng mạc trên dữ liệu đầu vào của người dùng.

CHƯƠNG 2: DỮ LIỆU VÀ TIỀN XỬ LÝ

2.1. Mô tả dữ liệu


2.1.1. CHASEDB1

a. Nguồn gốc:

Tập dữ liệu CHASEDB1 được công bố vào năm 2012 bởi Đại học Kingston, London phối hợp cùng St. George's, University of London. Dữ liệu này là một tập hợp con gồm các ảnh chụp võng mạc của trẻ em đa sắc tộc trong độ tuổi khoảng 10 tuổi, được trích xuất từ chương trình Child Heart and Health Study in England (CHASE) (Fraz et al., 2012).



Hình 2.1: Ảnh gốc



Hình 2.2: Ảnh ground truth

b. Kích thước của các ảnh bên trong:

Dataset chứa tổng cộng 84 ảnh, trong đó gồm có 28 ảnh võng mạc gốc và mỗi ảnh gốc đi kèm với 2 bản ground truth được gán nhãn thủ công bởi hai chuyên gia khác nhau. Chi tiết hơn, ảnh gốc sử dụng hệ màu RGB với kích thước 960 x 999 pixel, đi kèm với hai bản ground truth có cùng độ phân giải nhưng thuộc không gian màu xám. Các mask phân đoạn sử dụng giá trị pixel theo dạng nhị phân, nằm từ 0 đến 255.

c. Chia dữ liệu:

Mục đích sử dụng chính của tập dữ liệu này là dữ liệu nguồn để huấn luyện lần đầu cho mô hình. Dữ liệu từ đây được chia tách theo tỷ lệ:

- Train: 60 ảnh, trong đó dùng 20 ảnh gốc.
- Validation: 12 ảnh, trong đó dùng 4 ảnh gốc.
- Test: 12 ảnh, trong đó dùng 4 ảnh gốc.


2.2.2. DRIVE

a. Nguồn gốc:

Tập dữ liệu DRIVE (Digital Retinal Images for Vessel Extraction) được giới thiệu vào năm 2004, xuất phát từ một chương trình tầm soát bệnh vông mạc đái tháo đường tại Hà Lan. Nó được xây dựng bởi các chuyên gia từ Viện Khoa học Hình ảnh (Đại học Y khoa Utrecht) và Đại học Iowa (Staal et al., 2004).



Hình 2.3: Ảnh gốc



Hình 2.4: Ảnh ground truth

b. Kích thước của các ảnh bên trong:

Dataset ban đầu bao gồm 140 ảnh được chia làm 2 folder gồm test và train, trong đó gồm 20 ảnh train và 20 ảnh test. Với folder train, ảnh gốc đi kèm ảnh mask và ảnh thủ công được đánh dấu bởi chuyên gia, và folder test cũng có cấu trúc tương tự nhưng bổ sung thêm ảnh được đánh dấu bởi chuyên thứ hai. Thông số cụ thể hơn, ảnh gốc sử dụng hệ màu RGB với kích thước 584 x 565 pixel, ảnh mask và các ảnh được đánh dấu có độ phân giải tương đương nhưng thuộc không gian màu xám. Các mask phân đoạn sử dụng giá trị pixel theo dạng nhị phân, nằm từ 0 đến 255.

c. Chia dữ liệu:

Đối với tập dữ liệu DRIVE, mục đích sử dụng là làm dữ liệu học transfer và đánh giá cho mô hình. Từ đây, vì thiếu phần validation, nên thực hiện tách từ folder train, do đó cấu trúc hiện tại như sau:

- Train: 48 ảnh, trong đó dùng 16 ảnh gốc.
- Validation: 12 ảnh, trong đó dùng 4 ảnh gốc.
- Test: 80 ảnh, trong đó dùng 20 ảnh gốc.

2.2. Tiền xử lý và DataLoader

2.2.1. Đọc ảnh bằng Dataset class

Để quản lý việc nạp và xử lý dữ liệu hình ảnh, hai lớp dataset được xây dựng theo chuẩn của thư viện PyTorch, lần lượt tương ứng với tập dữ liệu CHASEDB1 và DRIVE. Cả hai lớp đều triển khai hai phương thức bắt buộc: trả về độ dài và truy xuất một mẫu

theo chỉ số. Thiết kế này cho phép tích hợp trực tiếp với cơ chế nạp dữ liệu theo batch của PyTorch, đảm bảo quá trình huấn luyện diễn ra nhất quán và có thể tái lập.

Đối với tập CHASEDB1, mỗi mẫu bao gồm một ảnh gốc và tối đa hai nhãn phân đoạn thủ công từ hai chuyên gia khác nhau. Ảnh gốc được đọc ở định dạng RGB, trong khi các mặt nạ nhãn được chuyển về ảnh xám để đơn giản hóa biểu diễn nhãn. Trong giai đoạn huấn luyện và kiểm định, chỉ nhãn từ chuyên gia thứ nhất được sử dụng làm ground truth. Riêng tập test sử dụng cả hai nhãn, cho phép đánh giá mô hình trên nhiều tiêu chuẩn tham chiếu khác nhau.

Còn với tập DRIVE, mỗi mẫu bao gồm ảnh gốc định dạng RGB, mask xác định vùng võng mạc hợp lệ, và nhãn thủ công, cả hai đều được đọc dưới dạng ảnh xám. Tương tự CHASEDB1, tập test của DRIVE được trang bị thêm nhãn từ chuyên gia thứ hai, tạo điều kiện để đánh giá hiệu suất mô hình một cách toàn diện và khách quan hơn.

2.2.2. Resize các ảnh và mask về cùng kích thước

Tất cả ảnh, mặt nạ và nhãn từ cả hai tập dữ liệu đều được chuẩn hóa về cùng một kích thước 256 x 256 pixel. Việc thống nhất kích thước đầu vào là bắt buộc để mô hình có thể xử lý dữ liệu theo batch và đảm bảo tính nhất quán trong suốt quá trình huấn luyện. Một điểm kỹ thuật quan trọng cần lưu ý là ảnh gốc so với mask và các ảnh manual được áp dụng phương pháp nội suy khác nhau khi resize. Trong khi ảnh gốc sử dụng phương pháp nội suy tuyến tính, còn các mask hoặc nhãn bắt buộc phải dùng phương pháp nội suy láng giềng gần nhất. Lý do là mask mang giá trị nhị phân đại diện cho nhãn lớp, mà cách tiếp cận này đảm bảo rằng các pixel ranh giới mạch máu vốn rất mảnh và có giá trị nhị phân rõ ràng, không bị làm mờ hay biến đổi trong quá trình thay đổi kích thước. Từ đó, thông tin được bảo toàn chất lượng và đảm bảo rằng không bị nhiễu bởi các giá trị pixel nội suy không mang ý nghĩa ngữ nghĩa, và ngăn chặn bất kỳ phương pháp nội suy nào tạo ra giá trị trung gian đều sẽ làm sai lệch thông tin nhãn.

2.2.3. Normalize ảnh

Sau khi được chuẩn hóa về kích thước, ảnh đầu vào tiếp tục được chuẩn hóa giá trị pixel theo các tham số mean và độ lệch chuẩn của ImageNet. Cụ thể, giá trị trung bình theo ba kênh màu RGB lần lượt là 0.485, 0.456 và 0.406, với độ lệch chuẩn tương ứng là 0.229, 0.224 và 0.225. Đây là bộ tham số chuẩn được sử dụng rộng rãi trong các bài toán thị giác máy tính khi mô hình có backbone được tiền huấn luyện trên ImageNet. Toàn bộ quy trình chuẩn hóa được tích hợp trong pipeline tăng cường dữ liệu của thư viện Albumentations, đảm bảo được áp dụng nhất quán trên tất cả các mẫu. Sau bước chuẩn hóa, ảnh được chuyển đổi thành tensor với thứ tự chiều theo chuẩn của PyTorch, cho ra kích thước cuối cùng là 3 x 256 x 256.

2.2.4. Chuyển mask về binary 0/1

Các mask và manual ban đầu mang giá trị pixel ở dạng nguyên, trong đó 0 biểu diễn vùng nền và 255 biểu diễn vùng mạch máu. Để phù hợp với yêu cầu tính toán của mô hình, các giá trị này được chuẩn hóa về khoảng nhị phân liên tục bằng cách chia cho 255, cho ra hai giá trị duy nhất là 0.0 và 1.0. Thao tác này được áp dụng nhất quán cho toàn bộ các loại mặt nạ trên cả hai tập dữ liệu, bao gồm mask và các nhãn phân đoạn thủ công. Sau khi chuẩn hóa, mask được chuyển đổi thành tensor số thực 32-bit và được bổ sung thêm một chiều kênh, cho ra kích thước cuối cùng là $1 \times 256 \times 256$. Việc thống nhất định dạng tensor giữa hai tập dữ liệu cũng tạo điều kiện thuận lợi để áp dụng cùng một hàm mất mát và quy trình đánh giá trong suốt quá trình thực nghiệm.

2.2.5. Data augmentation

Đối với tập huấn luyện, mỗi ảnh đầu vào được xử lý qua một chuỗi các phép biến đổi ngẫu nhiên nhằm tăng cường sự đa dạng của dữ liệu. Cụ thể, ảnh được lật ngang và lật dọc với xác suất mỗi phép là 0.5, đồng thời có thể được xoay ngẫu nhiên trong phạm vi 45 độ với xác suất tương tự. Ngoài ra, độ sáng và độ tương phản của ảnh cũng được điều chỉnh ngẫu nhiên với xác suất 0.2, giúp mô hình thích nghi tốt hơn với sự biến thiên về điều kiện chụp ảnh trong thực tế. Sau các bước tăng cường, ảnh được chuẩn hóa theo tham số ImageNet và chuyển đổi sang định dạng tensor để đưa vào mô hình. Toàn bộ những thay đổi này được áp dụng đồng thời lên cả ảnh gốc lẫn mask, manual, đảm bảo sự tương ứng không gian giữa ảnh và nhãn luôn được duy trì.

Trong tập test và validation, các phép biến đổi không được thực hiện nhằm giữ tính ổn định và khả năng tái lập của kết quả đánh giá. Lúc này chỉ bao gồm ba bước: chuẩn hóa kích thước về 256×256 , chuẩn hóa giá trị pixel theo ImageNet và chuyển sang tensor. Điều này phản ánh nguyên tắc chung rằng tăng cường dữ liệu chỉ được áp dụng trong quá trình huấn luyện để cải thiện khả năng tổng quát hóa, còn trong quá trình đánh giá thì mô hình cần được kiểm tra trên dữ liệu nhất quán và không bị biến đổi.

2.2.6. DataLoader

Sau bước tiền xử lý, các mẫu được nạp vào mô hình thông qua cơ chế DataLoader với cấu hình thống nhất cho cả hai tập dữ liệu. Mỗi batch bao gồm 4 ảnh, được xử lý song song bởi 2 luồng độc lập nhằm giảm thời gian chờ trong quá trình huấn luyện. Ở tập huấn luyện, thứ tự các mẫu được xáo trộn ngẫu nhiên sau mỗi epoch để tránh hiện tượng mô hình ghi nhớ thứ tự dữ liệu. Ngược lại, tập kiểm định và kiểm tra giữ nguyên thứ tự cố định, đảm bảo kết quả đánh giá có thể so sánh và tái lập một cách nhất quán.


Tập dữ liệu	Thành phần	Kích thước tensor
CHASEDB1	Ảnh gốc	(4, 3, 256, 256)
	Mask	(4, 1, 256, 256)
DRIVE	Ảnh gốc	(4, 3, 256, 256)
	Mask	(4, 1, 256, 256)
	Manual	(4, 1, 256, 256)

Bảng 2.1: Thống kê kích thước của mẫu theo từng tập dữ liệu

CHƯƠNG 3: PHƯƠNG PHÁP ĐỀ XUẤT

3.1 Mô Hình CNN-Based: DeepLabV3+-ResNet50

Trong đồ án này, mô hình DeepLabV3+-ResNet50 được lựa chọn làm đại diện cho nhóm mô hình dựa trên mạng nơ-ron tích chập (CNN-based model). Việc lựa chọn mô hình này phù hợp với yêu cầu của đề tài vì DeepLabV3+ là một kiến trúc chuyên dụng cho bài toán semantic segmentation, trong khi ResNet50 đóng vai trò backbone CNN mạnh, có khả năng trích xuất đặc trưng ảnh ở nhiều mức độ khác nhau. Đối với bài toán phân đoạn mạch máu võng mạc, mô hình cần vừa nhận diện được cấu trúc mạch máu lớn, vừa giữ được các chi tiết nhỏ và mảnh. Do đó, DeepLabV3+ là lựa chọn phù hợp nhờ khả năng khai thác ngữ cảnh không gian rộng thông qua atrous convolution và ASPP.



Hình 3.1: Kiến trúc mô hình DeepLabV3+-ResNet50

3.1.1. Cài đặt mô hình cho bài toán phân vùng nhị phân

Mô hình DeepLabV3+-ResNet50 được cài đặt kế thừa từ module nn.Module của PyTorch, đồng thời tận dụng trực tiếp kiến trúc DeepLabV3Plus từ thư viện segmentation_models_pytorch. Thay vì tự xây dựng thủ công toàn bộ kiến trúc, mô hình trong đồ án sử dụng implementation có sẵn và được cấu hình lại để phù hợp với bài toán phân đoạn nhị phân mạch máu võng mạc.

Khởi tạo backbone ResNet50: Mô hình sử dụng ResNet50 làm bộ mã hóa đặc trưng, được thiết lập thông qua tham số `encoder_name="resnet50"`. Đây là một kiến trúc CNN sâu, có khả năng trích xuất đặc trưng phân cấp từ ảnh đầu vào thông qua các khối tích chập và residual connection. Khi `pretrained_backbone=True`, backbone được khởi tạo với trọng số tiền huấn luyện ImageNet nhằm tận dụng khả năng học đặc trưng thị giác đã có sẵn, hỗ trợ quá trình huấn luyện hội tụ ổn định hơn.

Thiết lập DeepLabV3+ Head: Phần đầu của mô hình sử dụng kiến trúc DeepLabV3+, bao gồm module ASPP và decoder. Module ASPP khai thác đặc trưng ngữ cảnh đa tỉ lệ thông qua các nhánh atrous convolution với dilation rate lần lượt là (6, 12, 18) khi `output_stride=16`. Cách thiết kế này giúp mô hình mở rộng vùng nhìn nhận ngữ

cảnh mà không làm giảm thêm độ phân giải đặc trưng, phù hợp với bài toán phân đoạn các cấu trúc mạch máu có kích thước nhỏ và mảnh.

Điều chỉnh cho bài toán nhị phân: Do bài toán chỉ yêu cầu phân biệt hai vùng là mạch máu và nền, mô hình được cấu hình với `classes=1`. Khi đó, `segmentation_models_pytorch` tự động tạo `segmentation_head` gồm lớp tích chập `Conv2d(256 → 1)` để sinh ra một kênh logits duy nhất. Tham số `activation=None` được sử dụng để mô hình trả về logits thô thay vì xác suất, giúp quá trình huấn luyện có thể kết hợp trực tiếp với các hàm loss ổn định như `BCEWithLogits` hoặc `Dice/BCE loss`.

Xử lý `BatchNorm` trong nhánh pooling của ASPP: Trong quá trình huấn luyện với batch size nhỏ, nhánh image pooling của ASPP có thể tạo tensor kích thước `[1, C, 1, 1]`, gây lỗi cho `BatchNorm`. Vì vậy, code có cơ chế thay thế riêng `BatchNorm` trong nhánh pooling bằng `Identity`. Điều chỉnh này không làm thay đổi bản chất kiến trúc `DeepLabV3+`, mà chỉ giúp mô hình ổn định hơn khi huấn luyện trong điều kiện tài nguyên giới hạn.

3.1.2. Xử lý luồng dữ liệu và nội suy không gian Input/Output Shape

Quá trình lan truyền tiến của mô hình được thiết kế để đảm bảo đầu vào và đầu ra tuân thủ đúng định dạng của bài toán phân đoạn ảnh y sinh.

Ràng buộc đầu vào: Hàm `forward` kiểm tra tensor đầu vào phải có đúng 4 chiều theo định dạng `[B, 3, H, W]`. Trong đó `B` là batch size, `3` là số kênh màu RGB, còn `H` và `W` lần lượt là chiều cao và chiều rộng ảnh. Nếu tensor không có đúng 4 chiều hoặc không có đúng 3 kênh, mô hình sẽ dừng và phát sinh `ValueError`. Điều này giúp tránh lỗi sai định dạng dữ liệu khi huấn luyện hoặc suy luận.

Trích xuất đặc trưng bằng `ResNet50`: Ảnh đầu vào được đưa qua encoder `ResNet50` để tạo ra các mức đặc trưng khác nhau. Đặc trưng tầng thấp từ `Layer1` có độ phân giải khoảng $H/4 \times W/4$ và 256 kênh, được giữ lại để phục vụ skip connection trong decoder. Đặc trưng tầng sâu từ `Layer4` có độ phân giải khoảng $H/16 \times W/16$ và 2048 kênh, được đưa vào module ASPP để khai thác thông tin ngữ cảnh đa tỉ lệ.

Khôi phục chi tiết không gian bằng `DeepLabV3+` decoder: Sau ASPP, đặc trưng ngữ cảnh được đưa qua decoder của `DeepLabV3+`. Đặc trưng mức cao được nội suy lên $H/4 \times W/4$, sau đó kết hợp với đặc trưng tầng thấp từ `Layer1` đã được giảm số kênh bằng lớp `1x1 Conv` xuống 48 kênh. Sau phép nối kênh, tensor có kích thước xấp xỉ $H/4 \times W/4$ với 304 kênh, tiếp tục được xử lý bởi các lớp convolution trong decoder để phục hồi thông tin biên và cấu trúc mạch máu nhỏ.


Sinh logits nhị phân: Phần `segmentation_head` của thư viện tự động ánh xạ đặc trưng decoder từ 256 kênh về 1 kênh bằng `Conv2d(256 → 1)`, sau đó sử dụng `UpsamplingBilinear2d(scale_factor=4)` để đưa kết quả từ độ phân giải $H/4 \times W/4$ trở lại

kích thước ảnh gốc $H \times W$. Vì $\text{activation}=\text{None}$, bước kích hoạt cuối cùng là Identity, nên đầu ra cuối cùng của mô hình là logits thô có dạng $[B, 1, H, W]$.

Kết quả đầu ra: Tensor logits $[B, 1, H, W]$ biểu diễn điểm dự đoán chưa chuẩn hóa cho từng pixel. Trong huấn luyện, logits này được đưa trực tiếp vào hàm loss phù hợp. Trong suy luận, logits được chuyển thành bản đồ xác suất bằng hàm sigmoid, sau đó áp dụng threshold đã tune để tạo mặt nạ phân đoạn mạch máu nhị phân. Như vậy, mô hình vẫn giữ đúng bản chất CNN-based semantic segmentation, đồng thời đáp ứng yêu cầu đầu ra của bài toán phân vùng mạch máu võng mạc.

3.2. Kiến trúc mô hình SegFormer-B0

Trong khuôn khổ dự án phân vùng mạch máu võng mạc, bài toán đặt ra là phân loại nhị phân ở cấp độ điểm ảnh nhằm tách biệt hệ thống mạch máu ra khỏi nền võng mạc. Để giải quyết mục tiêu này, mô hình được xây dựng dựa trên kiến trúc Transformer thông qua biến thể SegFormer-B0. Khác với các mạng nơ-ron tích chập truyền thống, cơ chế Attention của SegFormer cho phép mô hình trích xuất đặc trưng toàn cục mạnh mẽ mà vẫn duy trì thiết kế nhẹ, phù hợp cho các bài toán phân vùng ảnh y tế.



Hình 3.2: Kiến trúc mô hình SegFormer

3.2.1. Cài đặt mô hình cho bài toán phân vùng nhị phân

Mô hình SegFormerB0 được cài đặt kế thừa từ module `nn.Module` của PyTorch, tận dụng trực tiếp lớp `SegformerForSemanticSegmentation` từ thư viện `transformers`. Quá trình tinh chỉnh cấu trúc mạng được thực hiện thông qua các bước thiết lập cốt lõi:

- *Khởi tạo từ trọng số tiền huấn luyện (Pre-trained Weights)*: Nhằm tận dụng khả năng trích xuất đặc trưng đã được học từ trước, mô hình mặc định tải bộ trọng số `nvidia/segformer-b0-finetuned-ade-512-512`. Việc khởi tạo thông qua

SegformerConfig.from_pretrained giúp mạng hội tụ nhanh hơn trong quá trình huấn luyện.

- *Điều chỉnh Segmentation Head*: Đặc thù của bài toán phân vùng mạch máu đòi hỏi đầu ra phải là xác suất thuộc về một lớp (mạch máu hoặc không). Do đó, cấu hình của SegFormer gốc (vốn thiết kế cho bộ dữ liệu ADE20K đa lớp) được can thiệp bằng cách thiết lập tham số num_labels=1.
- *Bỏ qua kích thước không khớp*: Khi thay đổi số lượng nhãn từ bộ tiền huấn luyện xuống còn 1, tham số ignore_mismatched_sizes=True được kích hoạt để mô hình bỏ qua sự bất đồng bộ kích thước ở lớp phân loại (classification head) cuối cùng, cho phép thay thế bằng một lớp tuyến tính mới tương ứng.

3.2.2. Xử lý luồng dữ liệu và nội suy không gian Input/Output Shape

Quá trình lan truyền tiến được lập trình với các cơ chế ràng buộc hình học khắt khe nhằm đảm bảo đầu ra đáp ứng chính xác mục tiêu của bài toán:

- *Ràng buộc đầu vào*: Hàm forward thực hiện kiểm tra số chiều của dữ liệu, yêu cầu tensor đầu vào phải là ảnh RGB tuân thủ nghiêm ngặt định dạng [B, 3, H, W]. Các tensor không đạt 4 chiều hoặc không có đúng 3 kênh màu sẽ bị chặn lại bằng ngoại lệ ValueError.
- *Khôi phục độ phân giải*: Do tính chất giảm kích thước không gian (downsampling) của các kiến trúc mạng sâu, đầu ra logits (điểm thô) từ mạng SegFormer thường nhỏ hơn so với ảnh gốc. Để giải quyết, hàm F.interpolate với chế độ nội suy song tuyến tính (mode="bilinear") và align_corners=False được sử dụng để nội suy logits trở lại kích thước không gian H x W ban đầu của đầu vào.
- *Kết quả đầu ra (Output Logits)*: Sau nội suy, kiến trúc mạng thực hiện xác thực lần cuối để đảm bảo tensor đầu ra có đúng 1 kênh (channel). Kết quả thu được là một ma trận logits có cấu trúc không gian hoàn chỉnh [B, 1, H, W], sẵn sàng để đưa qua hàm kích hoạt Sigmoid tính toán sai số (loss) trong huấn luyện.

Tính toàn vẹn của toàn bộ quá trình ánh xạ này được kiểm chứng thông qua một hàm phụ trợ check_io_shapes, trong đó mô hình nhận đầu vào giả lập [2, 3, 512, 512] và sinh ra kết quả chính xác [2, 1, 512, 512] mà không tính toán đạo hàm.

3.3 Loss function, metrics và transfer learning

3.3.1. Hàm mất mát và vấn đề mất cân bằng lớp

Bài toán phân vùng mạch máu võng mạc có đặc thù mất cân bằng lớp nghiêm trọng, trong đó số lượng điểm ảnh thuộc lớp mạch máu chiếm tỷ lệ nhỏ hơn nhiều so với

số lượng điểm ảnh nền. Nếu chỉ sử dụng hàm mất mát phân loại nhị phân thông thường, mô hình có thể thiên về dự đoán nền và bỏ sót các cấu trúc mạch máu nhỏ, đặc biệt là các nhánh mảnh ở vùng ngoại vi ảnh võng mạc. Vì vậy, trong đề án, hàm mất mát được lựa chọn phù hợp với từng mô hình.

Đối với mô hình DeepLabV3+-ResNet50, đề án sử dụng hàm mất mát kết hợp giữa BCEWithLogitsLoss và Tversky Loss. BCEWithLogitsLoss đánh giá sai số phân loại nhị phân ở cấp độ từng điểm ảnh và tích hợp sẵn hàm Sigmoid, giúp quá trình tối ưu ổn định hơn về mặt số học. Trong khi đó, Tversky Loss được sử dụng để xử lý tốt hơn sự mất cân bằng giữa lớp mạch máu và lớp nền bằng cách điều chỉnh mức phạt đối với false positive và false negative. Cấu hình huấn luyện sử dụng $bce_weight = 0.3$, $tversky_weight = 0.7$, $alpha = 0.3$, $beta = 0.7$, đồng thời có sử dụng pos_weight trong BCEWithLogitsLoss để tăng trọng số cho lớp mạch máu.

Đối với mô hình SegFormer-B0, đề án sử dụng BCEWithLogitsLoss cho bài toán phân vùng nhị phân. Do đầu ra của mô hình là logits một kênh có kích thước $[B, 1, H, W]$, BCEWithLogitsLoss phù hợp để tối ưu trực tiếp xác suất mạch máu/nền ở từng điểm ảnh mà không cần áp dụng Sigmoid thủ công trước khi tính loss. Như vậy, hai mô hình không sử dụng hoàn toàn cùng một hàm mất mát, mà được cấu hình theo đặc điểm kiến trúc và quá trình thực nghiệm riêng của từng mô hình.

3.3.2. Thang đo đánh giá

Để đánh giá toàn diện hiệu năng của mô hình, ma trận dự đoán (đã qua Sigmoid) được nhị phân hóa dựa trên một ngưỡng (threshold) và đối chiếu với ground-truth để tính toán các ma trận nhầm lẫn (TP, TN, FP, FN). Dự án tích hợp 6 thang đo chuẩn trong xử lý ảnh y tế:

- *Dice Score (F1-score)*: Đo lường trung bình điều hòa giữa độ xác chuẩn và độ bao phủ, là thang đo quan trọng nhất thể hiện độ tương đồng hình thái học: $2 * TP / (2 * TP + FP + FN)$.
- *IoU (Intersection over Union / Jaccard Index)*: Tỷ lệ phần giao trên phần hợp giữa dự đoán và thực tế: $TP / (TP + FP + FN)$.
- *Accuracy (Độ chính xác)*: Tỷ lệ điểm ảnh dự đoán đúng trên toàn bộ ảnh: $(TP + TN) / (TP + TN + FP + FN)$. Mặc dù được sử dụng, Accuracy không phản ánh độ tin cậy tuyệt đối do ảnh hưởng của class imbalance.
- *Precision (Độ chuẩn xác)*: Tỷ lệ điểm ảnh thực sự là mạch máu trong tổng số điểm ảnh được dự đoán là mạch máu: $TP / (TP + FP)$.
- *Recall (Độ bao phủ / Sensitivity)*: Tỷ lệ điểm ảnh mạch máu được nhận diện đúng trên tổng số điểm ảnh mạch máu thực tế: $TP / (TP + FN)$.

3.3.3. Transfer Learning

Thay vì huấn luyện từ đầu trên một tập dữ liệu giới hạn, đồ án áp dụng chiến lược học chuyển giao liên miền (cross-domain transfer learning) theo hướng huấn luyện trước trên CHASEDB1 và tinh chỉnh trên DRIVE. Cách tiếp cận này giúp mô hình tận dụng các đặc trưng mạch máu đã học từ tập dữ liệu nguồn, sau đó thích nghi với phân bố ảnh của tập dữ liệu đích.

Đối với mô hình DeepLabV3+-ResNet50, mô hình được khởi tạo với encoder ResNet50 sử dụng trọng số pretrained ImageNet. Phần encoder đóng vai trò trích xuất đặc trưng ảnh, trong khi segmentation head/decoder được tối ưu để tạo ra mặt nạ phân vùng nhị phân.

- Giai đoạn 1 - Source Training trên CHASEDB1: DeepLabV3+-ResNet50 được huấn luyện trên tập dữ liệu nguồn CHASEDB1 trong 40 epoch. Quá trình tối ưu sử dụng hai nhóm tốc độ học riêng biệt: CHASE_LR_BACKBONE = $1e-5$ cho phần backbone/encoder và CHASE_LR_HEAD = $1e-4$ cho phần segmentation head/decoder. Trọng số đạt kết quả kiểm định tốt nhất được lưu tại best_deeplabv3plus_resnet50_chase.pth.
- Giai đoạn 2 - Fine-tuning trên DRIVE: Sau giai đoạn huấn luyện nguồn, kiến trúc DeepLabV3+-ResNet50 được khởi tạo lại và tải trọng số tốt nhất từ CHASEDB1. Mô hình tiếp tục được tinh chỉnh trên tập dữ liệu đích DRIVE trong 50 epoch nhằm thích nghi với đặc điểm ảnh của DRIVE, bao gồm độ phân giải, điều kiện chiếu sáng, màu sắc nền võng mạc và phân bố nhiễu. Ở giai đoạn này, tốc độ học được giảm xuống, gồm DRIVE_LR_BACKBONE = $5e-6$ cho backbone/encoder và DRIVE_LR_HEAD = $5e-5$ cho segmentation head/decoder. Trọng số tốt nhất sau fine-tuning được lưu tại best_deeplabv3plus_resnet50_drive.pth.

Đối với mô hình SegFormer-B0, đồ án cũng áp dụng chiến lược học chuyển giao liên miền theo hai giai đoạn tương tự. Mô hình được khởi tạo từ trọng số pretrained nvidia/segformer-b0-finetuned-ade-512-512, sau đó điều chỉnh số lớp đầu ra về num_labels = 1 để phù hợp với bài toán phân vùng nhị phân mạch máu võng mạc.

- Giai đoạn 1 - Source Training trên CHASEDB1: SegFormer-B0 được huấn luyện trên tập dữ liệu nguồn CHASEDB1 trong 40 epoch. Quá trình tối ưu sử dụng hai nhóm tốc độ học riêng biệt: CHASE_LR_ENCODER = $1e-5$ cho phần encoder transformer và CHASE_LR_HEAD = $1e-4$ cho phần segmentation head. Trọng số đạt kết quả kiểm định tốt nhất được lưu tại best_segformer_b0_chase.pth.
- Giai đoạn 2 - Fine-tuning trên DRIVE: Sau khi hoàn tất giai đoạn huấn luyện trên CHASEDB1, mô hình SegFormer-B0 được khởi tạo lại và tải trọng số tốt nhất từ checkpoint best_segformer_b0_chase.pth. Mô hình tiếp tục được tinh chỉnh trên

tập dữ liệu DRIVE trong 50 epoch với tốc độ học nhỏ hơn, gồm $\text{DRIVE_LR_ENCODER} = 5e-6$ cho encoder và $\text{DRIVE_LR_HEAD} = 5e-5$ cho segmentation head. Checkpoint tốt nhất sau giai đoạn fine-tuning được lưu tại `best_segformer_b0_drive.pth`, đồng thời checkpoint triển khai cuối cùng được lưu dưới tên `best_segformer_b0.pth`.

Như vậy, cả hai mô hình đều được huấn luyện theo cùng chiến lược tổng quát: tận dụng trọng số pretrained, học đặc trưng ban đầu từ CHASEDB1 và fine-tune trên DRIVE. Tuy nhiên, mỗi mô hình sử dụng cách chia nhóm tham số riêng phù hợp với kiến trúc: DeepLabV3+-ResNet50 tách backbone và segmentation head/decoder, trong khi SegFormer-B0 tách encoder transformer và segmentation head.

3.3.4. Chiến lược tối ưu hóa và Huấn luyện

Quá trình tối ưu được thiết kế nhằm hạn chế quá khớp (overfitting), tăng độ ổn định khi huấn luyện và lưu lại mô hình có hiệu năng tốt nhất trên tập validation.

- Thuật toán tối ưu (Optimizer): Đồ án sử dụng AdamW (Adam with Weight Decay) với hệ số điều chuẩn $\text{weight_decay} = 1e-4$. Việc sử dụng AdamW giúp tách cơ chế weight decay khỏi cập nhật gradient của Adam, từ đó kiểm soát độ lớn tham số mạng tốt hơn và hỗ trợ giảm overfitting trong quá trình huấn luyện.
- Dừng sớm và lưu mô hình: Trong quá trình huấn luyện, mô hình được đánh giá trên tập validation sau mỗi epoch. Chỉ số chính dùng để theo dõi là `val_dice`. Khi `val_dice` đạt giá trị tốt hơn so với các epoch trước, trạng thái mô hình tốt nhất được lưu lại dưới dạng checkpoint. Đối với giai đoạn huấn luyện trên CHASEDB1, $\text{patience} = 10$; đối với giai đoạn fine-tuning trên DRIVE, $\text{patience} = 12$. Nếu chỉ số validation không cải thiện sau số epoch tương ứng, quá trình huấn luyện sẽ được dừng sớm.
- Threshold Tuning: Đầu ra trực tiếp của mô hình là logits. Trong giai đoạn suy luận, logits được đưa qua hàm sigmoid để chuyển thành probability map, sau đó áp dụng một ngưỡng nhị phân hóa để tạo prediction mask. Thay vì chỉ cố định ngưỡng tại 0.5, đồ án có thực hiện tìm kiếm ngưỡng trên tập validation để chọn threshold cho kết quả Dice tốt hơn. Với DeepLabV3+-ResNet50, lưới tìm kiếm threshold được thiết lập trong khoảng từ 0.30 đến 0.80 với bước nhảy 0.05. Ngưỡng tốt nhất sau đó được sử dụng khi đánh giá trên tập test.
- Tự động tính toán độ chính xác hỗn hợp (Automatic Mixed Precision - AMP): Nếu phần cứng hỗ trợ CUDA, cơ chế AMP được kích hoạt thông qua điều kiện `torch.cuda.is_available()`. Trong quá trình huấn luyện, `autocast` và `GradScaler` được sử dụng để thực hiện một phần phép toán ở độ chính xác thấp hơn, giúp tăng

tốc độ huấn luyện và giảm mức sử dụng VRAM, đồng thời vẫn duy trì độ ổn định của quá trình lan truyền ngược.

CHƯƠNG 4: THỰC NGHIỆM VÀ KẾT QUẢ

4.1 Thiết lập thực nghiệm

4.1.1. Môi trường thực nghiệm và Tính tái lập

Toàn bộ quy trình thực nghiệm huấn luyện mô hình được triển khai trên nền tảng Kaggle Notebook. Hệ thống tận dụng GPU để rút ngắn thời gian huấn luyện, đồng thời kích hoạt cơ chế Automatic Mixed Precision (AMP) khi CUDA khả dụng nhằm giảm mức sử dụng VRAM và tăng tốc độ tính toán.

Môi trường phần mềm và các thư viện cốt lõi bao gồm:

- Framework học sâu chính được sử dụng là PyTorch. Đối với mô hình DeepLabV3+-ResNet50, đồ án triển khai thông qua thư viện `segmentation_models_pytorch`, sử dụng kiến trúc DeepLabV3Plus với encoder `resnet50`. Encoder ResNet50 được khởi tạo với trọng số tiền huấn luyện ImageNet nhằm tận dụng khả năng trích xuất đặc trưng ảnh đã được học trước. Phần segmentation head của mô hình được cấu hình với `classes=1` để phù hợp với bài toán phân vùng nhị phân mạch máu võng mạc.
- Đối với mô hình SegFormer-B0, đồ án sử dụng thư viện Hugging Face Transformers để khởi tạo mô hình `SegformerForSemanticSegmentation` từ trọng số pretrained `nvidia/segformer-b0-finetuned-ade-512-512`, sau đó điều chỉnh số lớp đầu ra về `num_labels=1`.
- Các thư viện hỗ trợ tiền xử lý, tăng cường dữ liệu, xử lý ảnh và trực quan hóa gồm Albumentations, OpenCV, NumPy, Pandas, Matplotlib và Tqdm.

Để đảm bảo tính nhất quán và tăng khả năng tái lập kết quả giữa các lượt chạy, đồ án cố định hạt giống ngẫu nhiên thông qua hàm `set_seed` với giá trị `SEED = 42`. Hàm này đồng bộ các bộ sinh số ngẫu nhiên của Python, NumPy, PyTorch CPU và PyTorch CUDA. Ngoài ra, cấu hình `CuDNN` được thiết lập với `torch.backends.cudnn.deterministic = True` và `torch.backends.cudnn.benchmark = False` nhằm giảm tính bất định trong quá trình huấn luyện.

4.1.2. Bảng tham số huấn luyện

Các siêu tham số điều khiển quá trình huấn luyện được thiết lập riêng cho từng mô hình và từng giai đoạn transfer learning. Cả hai mô hình đều được huấn luyện theo hai giai đoạn: huấn luyện nguồn trên CHASEDB1 và tinh chỉnh trên DRIVE. Tuy nhiên, do khác biệt về kiến trúc và yêu cầu bộ nhớ, DeepLabV3+-ResNet50 và SegFormer-B0 sử


dùng batch size và hàm mất mát khác nhau. Việc so sánh mô hình được thực hiện trên cùng tập kiểm thử DRIVE và cùng hệ chỉ số đánh giá.

Siêu tham số	DeepLabV3+-ResNet50	SegFormer-B0
Kích thước ảnh đầu vào	512 x 512	512 x 512
Batch size	2	4
Optimizer	AdamW	AdamW
Weight decay	0.0001	0.0001
Random seed	42	42
Ngưỡng nhị phân hóa ban đầu	0.5	0.5
Epoch giai đoạn CHASEDB1	40	40
Epoch giai đoạn DRIVE	50	50
Learning rate CHASEDB1	Backbone: 1e-5; Head: 1e-4	Encoder: 1e-5; Head: 1e-4
Learning rate DRIVE	Backbone: 5e-6; Head: 5e-5	Encoder: 5e-6; Head: 5e-5
Early stopping CHASEDB1	Patience = 10	Patience = 10
Early stopping DRIVE	Patience = 12	Patience = 12
Loss function	BCEWithLogitsLoss + Tversky Loss	BCEWithLogitsLoss
Threshold tuning	0.30 đến 0.80; bước 0.05	Không tune trong notebook transfer; dùng 0.5

Bảng 4.1: Cấu hình siêu tham số huấn luyện của DeepLabV3+-ResNet50 và SegFormer-B0

4.1.3. Quy trình huấn luyện và lưu trữ

Luồng thực thi thực nghiệm được tổ chức khép kín tuần tự theo cấu trúc phân tầng bao gồm 3 bước cốt lõi nhằm phục vụ cho mục tiêu học chuyển giao



Hình 4.1. Quy trình huấn luyện và lưu trữ model

1. *Huấn luyện nền tảng*: Ở giai đoạn đầu, mô hình được huấn luyện trên tập dữ liệu nguồn CHASEDB1 nhằm học các đặc trưng hình thái chung của hệ mạch máu võng mạc. Sau mỗi epoch, mô hình được đánh giá trên tập validation thông qua các chỉ số như loss, Dice, IoU và Accuracy. Khi chỉ số validation Dice đạt giá trị tốt hơn so với các epoch trước, bộ trọng số tốt nhất được lưu lại dưới dạng checkpoint. Đối với DeepLabV3+-ResNet50, checkpoint giai đoạn nguồn được lưu tại best_deeplabv3plus_resnet50_chase.pth, đồng thời lịch sử huấn luyện được lưu vào deeplabv3plus_resnet50_chase_history.csv. Đối với SegFormer-B0, checkpoint tương ứng được lưu tại best_segformer_b0_chase.pth và lịch sử huấn luyện được lưu vào segformer_b0_chase_history.csv.
2. *Transfer Learning & Fine-tuning*: Sau khi hoàn tất giai đoạn huấn luyện nguồn, mô hình được khởi tạo lại theo đúng kiến trúc phân vùng nhị phân và tải trọng số tốt nhất từ checkpoint CHASEDB1. Quá trình fine-tuning được thực hiện trên tập DRIVE với tốc độ học nhỏ hơn để mô hình thích nghi với miền dữ liệu đích mà không làm mất hoàn toàn các đặc trưng đã học từ miền nguồn. Với DeepLabV3+-ResNet50, tốc độ học được tách thành DRIVE_LR_BACKBONE = 5e-6 cho backbone và DRIVE_LR_HEAD = 5e-5 cho segmentation head/decoder. Checkpoint tốt nhất sau fine-tuning được lưu tại best_deeplabv3plus_resnet50_drive.pth, kèm lịch sử huấn luyện deeplabv3plus_resnet50_drive_history.csv. Với SegFormer-B0, tốc độ học được

tách thành $\text{DRIVE_LR_ENCODER} = 5e-6$ cho encoder và $\text{DRIVE_LR_HEAD} = 5e-5$ cho segmentation head; checkpoint tốt nhất được lưu tại `best_segformer_b0_drive.pth`, đồng thời checkpoint triển khai cuối cùng được lưu dưới tên `best_segformer_b0.pth`.

3. *Threshold Tuning & Test Evaluation*: Sau giai đoạn fine-tuning, mô hình DeepLabV3+-ResNet50 thực hiện tìm kiếm ngưỡng nhị phân hóa trên tập validation DRIVE trong khoảng từ 0.30 đến 0.80 với bước nhảy 0.05 nhằm chọn ngưỡng tối ưu theo Dice Score. Ngưỡng tốt nhất sau đó được sử dụng để đánh giá trên tập test DRIVE và kết quả được lưu vào `deeplabv3plus_resnet50_drive_test_results.csv`. Đối với SegFormer-B0 trong notebook transfer, quá trình đánh giá sử dụng ngưỡng mặc định 0.5, kết quả DRIVE được lưu vào `segformer_b0_drive_results.csv`.

4.2. Kết quả từng mô hình

Trong phần này, hai mô hình chính của đề án được đánh giá trên tập kiểm thử DRIVE, bao gồm mô hình CNN-based DeepLabV3+-ResNet50 và mô hình attention-based SegFormer-B0. Kết quả được trình bày thông qua các chỉ số định lượng và hình ảnh trực quan gồm ảnh gốc, ground truth mask và prediction mask. Các chỉ số được tính sau khi đưa logits qua hàm sigmoid và áp dụng ngưỡng phân đoạn phù hợp cho từng mô hình.

4.2.1. Kết quả mô hình DeepLabV3+-ResNet50


Mô hình DeepLabV3+-ResNet50 được huấn luyện theo hướng transfer learning, sử dụng backbone ResNet50 tiền huấn luyện và phần DeepLabV3+ head cho bài toán phân đoạn nhị phân mạch máu võng mạc.

Mô hình	Threshold	Dice	IoU	Accuracy	Precision	Recall
DeepLabV3+-ResNet50	0.85	0.7173	0.5596	0.9487	0.6960	0.7471

Bảng 4.2: Kết quả tổng quan mô hình DeepLabV3+-ResNet50

Kết quả cho thấy DeepLabV3+-ResNet50 đạt $\text{Dice} = 0.7173$ và $\text{IoU} = 0.5596$, thể hiện khả năng phân đoạn tương đối tốt đối với cấu trúc mạch máu võng mạc. Chỉ số $\text{Recall} = 0.7471$ cao hơn Precision cho thấy mô hình có xu hướng phát hiện được nhiều vùng mạch máu hơn, bao gồm cả các nhánh mạch nhỏ. Tuy nhiên, Precision thấp hơn một chút phản ánh việc mô hình vẫn có thể sinh ra một số vùng dự đoán dương tính giả, đặc biệt ở các vùng nền có màu sắc hoặc biên độ sáng gần giống mạch máu.

Về mặt trực quan, prediction mask của DeepLabV3+-ResNet50 thường giữ được các nhánh mạch chính và nhiều nhánh phụ. Các mạch lớn được phân đoạn khá rõ, liên tục và có độ bao phủ tốt. Tuy nhiên, ở một số ảnh, dự đoán có thể hơi dày hơn ground truth hoặc xuất hiện nhiều nhỏ ở vùng nền. Điều này phù hợp với đặc điểm của mô hình khi recall cao hơn precision: mô hình ưu tiên không bỏ sót mạch máu, nhưng đôi lại có thể giữ thêm một số pixel không thuộc mạch.



Hình 4.2. Kết quả phân đoạn của DeepLabV3+-ResNet50 trên tập DRIVE.

Nên chọn hình visualization có đầy đủ ba phần Image / Ground Truth / Prediction, trong đó prediction thể hiện rõ cả mạch lớn và các nhánh nhỏ. Với DeepLabV3+-ResNet50, nên ưu tiên các mẫu mà prediction mask không quá dày và ít nhiễu nền để minh họa công bằng cho khả năng học đặc trưng của mô hình.

4.2.2. Kết quả mô hình SegFormer-B0


Mô hình SegFormer-B0 được sử dụng làm mô hình attention-based trong đồ án. Kiến trúc này tận dụng Transformer encoder với cơ chế self-attention để học mối quan hệ ngữ cảnh giữa các vùng ảnh, sau đó sinh logits phân đoạn nhị phân cho từng pixel.

Mô hình	Threshold	Dice	IoU	Accuracy	Precision	Recall
SegFormer-B0	0.50	0.7160	0.5579	0.9495	0.7070	0.7308

Bảng 4.3: Kết quả tổng quan mô hình SegFormer-B0

SegFormer-B0 đạt Dice = 0.7160 và IoU = 0.5579, gần tương đương với DeepLabV3+-ResNet50. Mô hình có Accuracy = 0.9495 và Precision = 0.7070, cao hơn một chút so với DeepLabV3+-ResNet50. Điều này cho thấy SegFormer-B0 có xu hướng dự đoán vùng mạch máu thận trọng hơn, giảm bớt các pixel dương tính giả ở vùng nền. Tuy nhiên, Recall = 0.7308 thấp hơn DeepLabV3+-ResNet50, nghĩa là mô hình có thể bỏ sót một số nhánh mạch nhỏ hoặc các đoạn mạch có độ tương phản thấp.

Về mặt trực quan, prediction mask của SegFormer-B0 thường có biên rõ và ít nhiễu hơn. Các mạch chính được giữ tương đối tốt, trong khi các vùng nền ít bị nhận nhầm thành mạch máu. Tuy nhiên, một số nhánh mạch rất mảnh có thể bị đứt đoạn hoặc không được phát hiện đầy đủ. Đây là đặc điểm thường thấy khi mô hình có precision cao hơn nhưng recall thấp hơn: kết quả nhìn sạch hơn, nhưng đôi khi kém nhạy với các chi tiết rất nhỏ.



Hình 4.3. Kết quả phân đoạn của SegFormer-B0 trên tập DRIVE.

Đối với SegFormer-B0, nên chọn các hình prediction trong notebook có cấu trúc mạch rõ, ít nhiễu nền và thể hiện được sự tương đồng với ground truth. Các output cell của notebook SegFormer đã lưu visualization theo dạng Image / Ground Truth / Prediction, phù hợp để đưa trực tiếp vào báo cáo.

4.2.3. Nhận xét so sánh trực quan

Nhìn chung, hai mô hình cho kết quả định lượng khá gần nhau. DeepLabV3+-ResNet50 đạt Dice và IoU nhỉnh hơn nhẹ, đồng thời có recall cao hơn, cho thấy khả năng phát hiện mạch máu đầy đủ hơn. Ngược lại, SegFormer-B0 có accuracy và precision cao hơn, phản ánh prediction mask sạch hơn và ít nhiễu nền hơn.

Từ các hình visualization, DeepLabV3+-ResNet50 phù hợp khi ưu tiên phát hiện nhiều nhánh mạch, đặc biệt là các vùng mạch nhỏ. SegFormer-B0 phù hợp khi ưu tiên mặt nạ phân đoạn gọn, ít false positive và có độ ổn định trực quan cao. Với bài toán phân đoạn mạch máu võng mạc, cả hai mô hình đều đáp ứng tốt yêu cầu nhận diện cấu trúc mạch chính, nhưng vẫn còn khó khăn ở các nhánh mạch rất nhỏ, mờ hoặc có độ tương phản thấp so với nền võng mạc.

4.3. So sánh và phân tích lỗi

Sau khi đánh giá riêng từng mô hình, phần này tiến hành so sánh DeepLabV3+-ResNet50 và SegFormer-B0 trên cùng tập kiểm thử DRIVE. Việc so sánh được thực hiện dựa trên các chỉ số định lượng như Dice, IoU, Accuracy, Precision, Recall và F1-score, đồng thời kết hợp với quan sát trực quan từ các ảnh phân đoạn.

Mô hình	Threshold	Dice	IoU	Accuracy	Precision	Recall
DeepLabV3+-ResNet50	0.85	0.7173	0.5596	0.9487	0.6960	0.7471
SegFormer-B0	0.50	0.7160	0.5579	0.9495	0.7070	0.7308

Bảng 4.4 trình bày kết quả so sánh hai mô hình trên tập kiểm thử DRIVE.

Kết quả cho thấy hai mô hình đạt hiệu năng khá tương đồng. DeepLabV3+-ResNet50 đạt Dice/F1-score và IoU nhỉnh hơn nhẹ so với SegFormer-B0, lần lượt là 0.7173 và 0.5596. Trong khi đó, SegFormer-B0 có Accuracy và Precision cao hơn, đạt 0.9495 và 0.7070. Điều này cho thấy DeepLabV3+-ResNet50 có xu hướng phát hiện được nhiều vùng mạch máu hơn, còn SegFormer-B0 cho kết quả thận trọng và ít false positive hơn.

Về Recall, DeepLabV3+-ResNet50 đạt 0.7471, cao hơn SegFormer-B0 với 0.7308. Điều này phản ánh khả năng bao phủ mạch máu của DeepLabV3+-ResNet50 tốt hơn, đặc biệt ở một số vùng có mạch nhỏ hoặc mạch có độ tương phản thấp. Tuy nhiên, Precision của DeepLabV3+-ResNet50 thấp hơn, cho thấy mô hình có thể dự đoán dư một số pixel nền thành mạch máu. Ngược lại, SegFormer-B0 có Precision cao hơn nhưng Recall thấp hơn, tức là mật nạ dự đoán sạch hơn nhưng có khả năng bỏ sót một số nhánh mạch nhỏ.

4.3.1. So sánh trực quan

Khi quan sát các ảnh trực quan gồm ảnh gốc, ground truth và prediction, cả hai mô hình đều phân đoạn tương đối tốt các mạch máu lớn. Các nhánh chính gần optic disc và các mạch có độ tương phản rõ thường được phát hiện liên tục. Đây là các vùng có đặc trưng hình học và màu sắc rõ ràng, nên cả CNN-based model và attention-based model đều học được tương đối ổn định.

Đối với các mạch máu nhỏ, sự khác biệt giữa hai mô hình trở nên rõ hơn. DeepLabV3+-ResNet50 thường có xu hướng giữ lại nhiều nhánh mạch hơn, kể cả các nhánh mảnh. Điều này phù hợp với chỉ số Recall cao hơn. Tuy nhiên, một số vùng

prediction có thể dày hơn ground truth hoặc xuất hiện các đoạn mạch giả không thật sự tồn tại. SegFormer-B0 thường tạo mask gọn hơn, ít nhiễu hơn, nhưng đôi khi các nhánh mạch nhỏ bị đứt đoạn hoặc không được phát hiện đầy đủ.

Về độ dày của mask, DeepLabV3+-ResNet50 có thể sinh ra các vùng mạch hơi dày, đặc biệt ở các mạch chính hoặc vùng có biên ảnh không rõ. Trong khi đó, SegFormer-B0 thường cho biên mảnh và sạch hơn, nhưng ở một số trường hợp có thể làm mất các đoạn mạch yếu. Sự khác biệt này thể hiện sự đánh đổi giữa Recall và Precision: tăng khả năng phát hiện mạch thường đi kèm với nguy cơ tăng false positive, trong khi prediction sạch hơn có thể dẫn đến bỏ sót mạch nhỏ.

4.3.2. Phân tích lỗi

Một lỗi phổ biến của cả hai mô hình là bỏ sót các mạch máu nhỏ, đặc biệt ở vùng ngoại vi võng mạc hoặc các vùng có độ tương phản thấp. Các mạch này thường rất mảnh, có cường độ màu gần giống nền và đôi khi không liên tục trong ground truth. Do đó, mô hình khó phân biệt giữa mạch thật và nhiễu nền.

Lỗi thứ hai là prediction quá dày hoặc quá mảnh so với ground truth. Với DeepLabV3+-ResNet50, một số prediction có thể dày hơn do mô hình giữ lại nhiều pixel có xác suất thuộc lớp mạch máu. Điều này làm tăng Recall nhưng có thể làm giảm Precision. Với SegFormer-B0, prediction có thể mảnh hơn và sạch hơn, nhưng các nhánh nhỏ dễ bị mất nếu xác suất dự đoán không vượt qua threshold.

Lỗi false positive cũng xuất hiện quanh vùng optic disc. Đây là vùng sáng mạnh, có biên rõ và nhiều cấu trúc mạch hội tụ, khiến mô hình dễ nhầm một số vùng sáng hoặc ranh giới mô thành mạch máu. Ngoài optic disc, các vùng nền có biến đổi ánh sáng hoặc texture gần giống mạch máu cũng có thể tạo ra dự đoán sai.

Threshold có ảnh hưởng lớn đến chất lượng prediction mask. Với threshold thấp, mô hình giữ lại nhiều pixel hơn, giúp tăng Recall nhưng dễ làm mask dày và tăng false positive. Với threshold cao, prediction sạch hơn và Precision tăng, nhưng các mạch nhỏ có xác suất thấp dễ bị loại bỏ. Điều này giải thích vì sao DeepLabV3+-ResNet50 cần threshold cao hơn trong kết quả cuối cùng, trong khi SegFormer-B0 sử dụng threshold 0.50. Việc tuning threshold là cần thiết vì cùng một probability map, lựa chọn threshold khác nhau có thể làm thay đổi đáng kể Dice, Precision và Recall.

4.3.3. Ảnh hưởng của domain shift giữa CHASEDB1 và DRIVE

Trong đồ án, mô hình được huấn luyện theo hướng transfer learning từ CHASEDB1 sang DRIVE. Tuy cùng là dữ liệu ảnh võng mạc, hai bộ dữ liệu vẫn có khác biệt về thiết bị chụp, độ phân giải, màu sắc, độ sáng, tương phản và đặc điểm annotation.


Sự khác biệt này tạo ra hiện tượng domain shift, khiến các đặc trưng học được từ CHASEDB1 không hoàn toàn khớp với DRIVE.

Domain shift có thể làm mô hình dự đoán kém ổn định hơn ở các ảnh có màu nền, độ sáng hoặc cấu trúc mạch khác với dữ liệu nguồn. Các vùng mạch nhỏ và vùng ngoại vi thường chịu ảnh hưởng rõ nhất, vì chúng phụ thuộc nhiều vào chất lượng ảnh và cách tiền xử lý. Việc fine-tune trên DRIVE giúp giảm bớt domain shift, nhưng không thể loại bỏ hoàn toàn sự khác biệt giữa hai miền dữ liệu.

CHƯƠNG 5: ỨNG DỤNG DEMO

5.1 Mục tiêu và chức năng ứng dụng

Sau khi hoàn thành quá trình huấn luyện và đánh giá mô hình phân đoạn mạch máu võng mạc, nhóm tiến hành xây dựng một ứng dụng demo nhằm trực quan hóa kết quả và mô phỏng quá trình suy luận (Inference) trong môi trường thực tế. Ứng dụng được phát triển bằng Streamlit, cho phép người dùng dễ dàng tương tác với mô hình thông qua giao diện web đơn giản và thân thiện.



Hình 5.1. Giao diện kết quả phân đoạn mạch máu võng mạc trên ứng dụng Streamlit

Mục tiêu chính của ứng dụng là cung cấp một công cụ hỗ trợ thử nghiệm khả năng phân đoạn mạch máu võng mạc trên các ảnh đầu vào mới. Thông qua ứng dụng, người dùng có thể tải lên ảnh võng mạc, lựa chọn mô hình mong muốn và quan sát trực tiếp kết quả phân đoạn mà không cần thực hiện các thao tác dòng lệnh phức tạp.


Chức năng	Mô tả cập nhật
Tải ảnh võng mạc	Người dùng tải ảnh PNG, JPG hoặc JPEG. Ảnh được chuyển sang RGB để xử lý thống nhất.

Lựa chọn mô hình	Ứng dụng hỗ trợ SegFormer-B0 và DeepLabV3+-ResNet50, mỗi mô hình có checkpoint và threshold mặc định riêng.
Điều chỉnh threshold	Sidebar có Prediction threshold slider, cho phép kiểm soát bước chuyển Probability Map thành binary vessel mask.
Inference	Model được load từ checkpoint, chạy trên CUDA nếu có, ngược lại dùng CPU. Ảnh input được resize về 512 x 512.
Trực quan hóa kết quả	Hiển thị Original Image, Overlay, Prediction Mask và Colored Morphology Map.
Phân tích mạch máu	Tính vessel density, branch/junction/endpoint count, connected components, skeleton length và các chỉ số normalized.
Technical Vessel Dashboard	Tab kỹ thuật giải thích input summary, công thức, morphology metrics, risk score, processing pipeline và export summary.
Export	Cho phép tải Prediction Mask, Overlay Image và Technical Summary dạng Markdown.

Bảng 5.1: Các chức năng chính của ứng dụng.

5.1.1. Tải ảnh võng mạc

Người dùng có thể tải lên ảnh võng mạc định dạng PNG, JPG hoặc JPEG thông qua giao diện web. Sau khi tải lên, ảnh gốc sẽ được hiển thị trực tiếp trên màn hình để người dùng kiểm tra dữ liệu đầu vào.



Hình 5.2. Chức năng tải ảnh võng mạc lên hệ thống

5.1.2. Lựa chọn mô hình phân đoạn

Ứng dụng hỗ trợ hai mô hình đã được huấn luyện:

- SegFormer-B0
- DeepLabV3+-ResNet50



Hình 5.3. Chức năng lựa chọn mô hình phân đoạn

Người dùng có thể lựa chọn mô hình mong muốn để thực hiện suy luận và so sánh kết quả giữa các kiến trúc khác nhau.

5.1.3. Thực hiện phân đoạn tự động


Sau khi nhấn nút chạy mô hình, hệ thống sẽ tự động:

- Tiền xử lý ảnh đầu vào.
- Nạp trọng số đã huấn luyện.
- Thực hiện suy luận trên GPU hoặc CPU.
- Sinh ra mặt nạ phân đoạn mạch máu (Prediction Mask).

5.1.4. Trực quan hóa kết quả

Kết quả được hiển thị dưới nhiều dạng khác nhau nhằm hỗ trợ người dùng quan sát trực quan:

- Ảnh gốc (Original Image)
- Mặt nạ phân đoạn (Prediction Mask)
- Ảnh chồng lớp (Overlay)
- Bản đồ hình thái học màu (Colored Morphology Map)



Hình 5.4. Kết quả phân đoạn gồm ảnh gốc, mặt nạ phân đoạn, ảnh Overlay và ảnh Skeleton

Trong đó ảnh Overlay được tạo bằng cách chồng mặt nạ phân đoạn lên ảnh gốc giúp người dùng dễ dàng quan sát vị trí các mạch máu được phát hiện. Colored Morphology Map là ảnh trực quan hóa đồng thời các thành phần hình thái học của hệ thống mạch máu. Trong đó, vùng mạch máu dự đoán, đường skeleton, các điểm cuối (endpoint) và điểm giao nhánh (junction) được biểu diễn bằng các màu khác nhau nhằm hỗ trợ người dùng quan sát cấu trúc mạch máu một cách trực quan hơn.

5.1.5. Phân tích đặc trưng mạch máu

Bên cạnh chức năng phân đoạn, ứng dụng còn tích hợp module phân tích mạch máu nhằm trích xuất một số đặc trưng cơ bản của hệ thống mạch máu võng mạc, bao gồm:

Chỉ số	Cách hiểu	Vai trò trong dashboard
Vessel Density	Tỷ lệ pixel được phân loại là mạch máu trên tổng số pixel.	Đánh giá mức độ bao phủ vessel trong ảnh.
Branch Count	Số nhánh vessel được phát hiện từ skeleton.	Mô tả cấu trúc phân nhánh của mạng mạch máu.
Junction Count	Số điểm giao hoặc phân nhánh trên skeleton.	Đại diện cho độ phức tạp topology.
Endpoint Count	Số điểm cuối của skeleton.	Gợi ý mức độ terminal hoặc khả năng rời rạc của vessel segments.
Connected Components	Số vùng vessel tách rời trong binary mask.	Đánh giá tính liên thông của mask.

Skeleton Length	Tổng số pixel trên skeleton centerline.	Ước lượng chiều dài cấu trúc mạch sau thinning.
Branch Density	Junction Count chia cho Skeleton Length.	Chuẩn hóa độ phức tạp phân nhánh theo chiều dài skeleton.
Endpoint Ratio	Endpoint Count chia cho Skeleton Length.	Chuẩn hóa mức độ terminal/fragmentation theo skeleton.
Fragmentation Index	Connected Components chia cho Skeleton Length.	Chuẩn hóa mức độ rời rạc của mask.
Risk Score	Điểm rule-based từ density và morphology metrics.	Minh họa cơ chế đánh giá nguy cơ tham khảo, không có giá trị lâm sàng.

Bảng 5.2: Phân tích đặc trưng mạch máu

Vessel analysis

Vessel Density	Branch Count	Junction Count	Endpoint Count	Connected Compo...	Risk Score
18.78%	157	243	324	177	30

High vessel density

11,737 vessel pixels / 62,500 total pixels

Inference debug

Raw Output Min	Raw Output Max	Probability Min	Probability Max	Threshold	Vessel Pixels	Total Pixels
-11.8...	7.99...	0.00...	0.99...	0.15...	11,737	62,500

Raw output shape: (1, 1, 512, 512) | Preprocessing: ImageNet normalized

Hình 5.5. Các chỉ số phân tích đặc trưng mạch máu trên ứng dụng

Các chỉ số này giúp minh họa khả năng mở rộng của hệ thống sang các bài toán phân tích hình thái mạch máu trong tương lai.

5.1.6. Tải kết quả về máy

Ứng dụng cho phép người dùng tải xuống để phục vụ mục đích lưu trữ hoặc báo cáo kết quả:


- Prediction Mask
- Overlay Image

- Morphology Map
- Technical Summary

Cần lưu ý rằng ứng dụng được xây dựng phục vụ mục đích nghiên cứu và học tập. Kết quả phân đoạn và các chỉ số phân tích không được sử dụng như công cụ chẩn đoán y khoa.

5.1.7. Technical Vessel Dashboard

Dashboard kỹ thuật được xây dựng nhằm hỗ trợ việc phân tích và giải thích các kết quả phân đoạn. Bên cạnh việc hiển thị các chỉ số hình thái học của hệ thống mạch máu, dashboard còn cung cấp phần giải thích ý nghĩa của từng chỉ số, bảng diễn giải kết quả, thông tin đầu vào của mô hình và cơ chế tính toán Risk Score. Điều này giúp người dùng không chỉ quan sát kết quả mà còn hiểu rõ hơn về cấu trúc mạch máu được mô hình phát hiện.



Hình 5.6: Technical Vessel Dashboard

Ứng dụng còn cung cấp Technical Vessel Dashboard nhằm hỗ trợ người dùng theo dõi chi tiết các đặc trưng hình thái học của hệ thống mạch máu. Dashboard này hiển thị thông tin đầu vào của mô hình, giải thích ý nghĩa của các chỉ số Vessel Density, Branch Count, Junction Count, Endpoint Count, Connected Components và Risk Score. Ngoài ra, hệ thống còn cung cấp bảng diễn giải các chỉ số và chức năng xuất báo cáo kỹ thuật phục vụ mục đích nghiên cứu và học tập.

5.2 Pipeline xử lý trong ứng dụng

Hình 5.7 trình bày pipeline xử lý của ứng dụng demo phân đoạn mạch máu võng mạc được xây dựng trong đồ án.

Quy trình bắt đầu khi người dùng tải lên ảnh võng mạc thông qua giao diện Streamlit. Ảnh đầu vào được thực hiện các bước tiền xử lý như chuyển đổi định dạng màu, thay đổi kích thước và chuẩn hóa dữ liệu để phù hợp với dữ liệu huấn luyện của mô hình.


Sau giai đoạn tiền xử lý, người dùng có thể lựa chọn một trong hai mô hình đã được triển khai là SegFormer-B0 hoặc DeepLabV3+-ResNet50. Ảnh sau đó được đưa vào mô hình để thực hiện suy luận và sinh ra bản đồ xác suất (Probability Map). Thông qua kỹ thuật Thresholding, bản đồ xác suất được chuyển đổi thành mặt nạ phân đoạn nhị phân (Binary Vessel Mask). Từ kết quả phân đoạn, hệ thống tiếp tục tạo ảnh Overlay bằng cách chồng mặt nạ mạch máu lên ảnh võng mạc gốc nhằm hỗ trợ trực quan hóa kết quả. Đồng thời, mặt nạ phân đoạn được sử dụng để thực hiện Skeletonization và trích xuất các đặc trưng hình thái học của hệ thống mạch máu.

Từ các đặc trưng hình thái học được trích xuất, hệ thống tiếp tục xây dựng Colored Morphology Map nhằm trực quan hóa các thành phần quan trọng của cấu trúc mạch máu như skeleton centerline, endpoint và junction point trên cùng một ảnh.

Các đặc trưng được tính toán bao gồm mật độ mạch máu (Vessel Density), số lượng nhánh (Branch Count), số lượng điểm giao (Junction Count), số lượng điểm cuối (Endpoint Count) và số lượng thành phần liên thông (Connected Components). Dựa trên các thông tin này, hệ thống tiến hành tính toán Risk Score nhằm cung cấp thêm thông tin tham khảo về cấu trúc mạch máu trong ảnh.

Cuối cùng, toàn bộ kết quả được hiển thị trên giao diện ứng dụng bao gồm ảnh gốc, Prediction Mask, Overlay Image, Colored Morphology Map cùng các chỉ số phân tích hình thái học của hệ thống mạch máu. Người dùng cũng có thể tải xuống các kết quả phân đoạn để phục vụ mục đích nghiên cứu và báo cáo.

Pipeline này cho phép tích hợp toàn bộ quá trình từ ảnh đầu vào đến kết quả phân đoạn và phân tích mạch máu trong một môi trường trực quan, thuận tiện cho việc trình diễn và đánh giá mô hình.



Hình 5.7. Pipeline xử lý của hệ thống phân đoạn và phân tích mạch máu võng mạc

CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Tổng kết kết quả đạt được

Trong phạm vi đồ án, nhóm đã nghiên cứu và xây dựng thành công hệ thống phân đoạn mạch máu võng mạc dựa trên các kỹ thuật Deep Learning hiện đại. Hệ thống được triển khai trên hai bộ dữ liệu chuẩn là DRIVE và CHASEDB1, đồng thời thực hiện đầy đủ các bước từ tiền xử lý dữ liệu, huấn luyện mô hình, đánh giá kết quả cho đến xây dựng ứng dụng demo trực quan.

Về mặt mô hình học sâu, đồ án đã triển khai và đánh giá hai kiến trúc phân đoạn ảnh bao gồm SegFormer-B0 và DeepLabV3+-ResNet50. Kết quả thực nghiệm cho thấy cả hai mô hình đều đạt hiệu năng cao trên tập dữ liệu kiểm thử. DeepLabV3+-ResNet50 đạt Dice Score 0.7173 và IoU 0.5596, trong khi SegFormer-B0 đạt Dice Score 0.7160 và IoU 0.5579. Về Accuracy, SegFormer-B0 đạt 0.9495, cao hơn nhẹ so với DeepLabV3+-ResNet50 đạt 0.9487. Kết quả cho thấy hai mô hình có hiệu năng tương đương và đều được tích hợp vào hệ thống, trong đó SegFormer-B0 được sử dụng làm mô hình mặc định trong ứng dụng Streamlit.

Bên cạnh quá trình đánh giá mô hình, nhóm cũng xây dựng thành công pipeline trực quan hóa kết quả phân đoạn bao gồm ảnh gốc, Prediction Mask, Overlay Image và Skeleton Vessel Map. Điều này giúp việc quan sát và đánh giá chất lượng phân đoạn trở nên trực quan và dễ dàng hơn.

Một điểm nổi bật của đồ án là việc mở rộng từ bài toán phân đoạn đơn thuần sang phân tích đặc trưng mạch máu. Hệ thống có khả năng tính toán các chỉ số như Vessel Density, Branch Count, Junction Count, Endpoint Count và Connected Components. Các đặc trưng này được sử dụng để xây dựng cơ chế đánh giá Risk Score nhằm minh họa khả năng ứng dụng của hệ thống trong các bài toán phân tích ảnh y sinh.

Ngoài ra, nhóm đã phát triển ứng dụng Streamlit cho phép người dùng tải lên ảnh võng mạc, lựa chọn mô hình phân đoạn, thực hiện suy luận và quan sát kết quả trực tiếp trên giao diện web. Ứng dụng đóng vai trò là môi trường trình diễn hoàn chỉnh, giúp minh họa khả năng hoạt động thực tế của hệ thống.

Nhìn chung, các mục tiêu đặt ra ban đầu của đồ án đã được hoàn thành, bao gồm xây dựng mô hình phân đoạn, đánh giá hiệu năng, trực quan hóa kết quả và triển khai ứng dụng demo phục vụ nghiên cứu và học tập.

6.2 Hạn chế và hướng phát triển

Mặc dù đạt được những kết quả khả quan, hệ thống vẫn còn tồn tại một số hạn chế nhất định.

Thứ nhất, kích thước bộ dữ liệu huấn luyện còn tương đối nhỏ. Các bộ dữ liệu DRIVE và CHASEDB1 chỉ chứa số lượng ảnh giới hạn nên chưa thể phản ánh đầy đủ sự đa dạng của các trường hợp lâm sàng trong thực tế. Điều này có thể ảnh hưởng đến khả năng tổng quát hóa của mô hình khi áp dụng trên các nguồn dữ liệu khác.

Thứ hai, đồ án mới tập trung vào bài toán phân đoạn nhị phân mạch máu võng mạc mà chưa thực hiện các nhiệm vụ nâng cao như phát hiện tổn thương võng mạc, phân loại bệnh lý hoặc đánh giá mức độ nghiêm trọng của bệnh. Vì vậy hệ thống hiện tại chưa thể được sử dụng như một công cụ hỗ trợ chẩn đoán hoàn chỉnh.

Thứ ba, cơ chế Risk Score được xây dựng dựa trên các luật thủ công và các đặc trưng hình thái học cơ bản. Kết quả chỉ mang tính chất minh họa phục vụ nghiên cứu, chưa được kiểm chứng trên dữ liệu lâm sàng và không có giá trị chẩn đoán y khoa.

Trong tương lai, hệ thống có thể được phát triển theo các hướng sau:

- Mở rộng bộ dữ liệu huấn luyện bằng cách sử dụng thêm các bộ dữ liệu võng mạc công khai khác nhằm nâng cao khả năng tổng quát hóa của mô hình.
- Nghiên cứu và triển khai các kiến trúc hiện đại hơn như SegFormer-B1, SegFormer-B2, Swin Transformer hoặc các mô hình Foundation Model dành cho ảnh y khoa.
- Áp dụng các kỹ thuật Data Augmentation nâng cao để cải thiện chất lượng học của mô hình.
- Kết hợp bài toán phân đoạn với các bài toán phân loại bệnh võng mạc như Diabetic Retinopathy hoặc Hypertensive Retinopathy.
- Xây dựng hệ thống đánh giá nguy cơ dựa trên mô hình học máy thay vì sử dụng các luật thủ công.
- Tối ưu hóa ứng dụng và triển khai trên nền tảng điện toán đám mây nhằm hỗ trợ truy cập từ nhiều thiết bị khác nhau.
- Tích hợp thêm các chức năng thống kê và phân tích chuyên sâu phục vụ nghiên cứu ảnh y sinh.

Với những hướng phát triển trên, hệ thống có tiềm năng trở thành một nền tảng hỗ trợ nghiên cứu và phân tích ảnh võng mạc hiệu quả hơn trong tương lai.

TÀI LIỆU THAM KHẢO

1. Fraz, M. M., Remagnino, P., Hoppe, A., Uyyanonvara, B., Rudnicka, A. R., Owen, C. G., & Barman, S. A. (2012). An ensemble classification-based approach applied to retinal blood vessel segmentation. *IEEE Transactions on Biomedical Engineering*, 59(9), 2538–2548. <https://doi.org/10.1109/TBME.2012.2205687>
2. Staal, J., Abramoff, M. D., Niemeijer, M., Viergever, M. A., & van Ginneken, B. (2004). Ridge-based vessel segmentation in color images of the retina. *IEEE Transactions on Medical Imaging*, 23(4), 501–509. <https://doi.org/10.1109/TMI.2004.825627>
3. Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., & Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. In Proceedings of the European Conference on Computer Vision (ECCV) (pp. 801-818). <https://arxiv.org/abs/1802.02611>
4. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 770-778). <https://doi.org/10.1109/CVPR.2016.90>
5. Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J. M., & Luo, P. (2021). SegFormer: Simple and efficient design for semantic segmentation with transformers. In Advances in Neural Information Processing Systems, 34 (pp. 12077-12090). <https://arxiv.org/abs/2105.15203>

PHỤ LỤC

TÊN KHO LƯU TRỮ:

DL-retinal-vessel-segmentation-final

<https://github.com/DannyPhongcoderso1/DL-retinal-vessel-segmentation-final.git>

BẢNG PHÂN CÔNG:

Thành viên	Phần chính
Dương Quang Đông	Dữ liệu, EDA, tiền xử lý ảnh, xuất ảnh tập dữ liệu, chức năng tính toán trong app
Nguyễn Quốc Khánh	Cài đặt, huấn luyện và đánh giá mô hình SegFormer-B0
Ngô Chánh Phong	Cài đặt, huấn luyện và đánh giá mô hình DeepLabV3+ - ResNet50
Nguyễn Đình Lương	Phụ trách Metrics, Evaluation, Visualization, Feature Extraction và UI.

KẾT QUẢ KIỂM TRA ĐẠO VĂN:

https://ev.turnitin.com/app/carta/en_us/?lang=en_us&ro=103&u=1156127912&student_u ser=1&o=2979119780

DL

ORIGINALITY REPORT

19%

SIMILARITY INDEX

15%

INTERNET SOURCES

10%

PUBLICATIONS

%

STUDENT PAPERS